



Large Brain Model for Learning Generic Representations with Tremendous EEG Data in BCI

☼ 상태	완료
≡ Journal	ICLR
≡ Year	2024.05
≡ Summary	대규모 EEG 데이터를 활용한 Pre-training 기반의 Transformer 모델인 LaBraM을 제안
≡ Limitations	더 큰 규모의 EEG 데이터 확보, 멀티모달 학습, 경량화 모델 연구
🔗 Link	https://arxiv.org/abs/2405.18765
≡ category	EEG LLM Pre-training Time Series

<https://github.com/935963004/LaBraM>

Introduction

EEG는 비침습적인 방식으로 뇌의 전기 활동을 기록하는 방법으로, 다양한 뇌-컴퓨터 인터페이스(BCI) 연구에서 활용된다. 하지만 기존의 EEG 기반 딥러닝 모델들은 특정 데이터셋과 응용 분야에 맞춰져 있어 일반화 성능이 부족하고, 대규모 학습이 어렵다.

최근 LLM의 성공은 EEG 데이터에서도 대규모 학습을 통한 일반화 가능성을 탐색할 수 있는 기회를 제공했다. 하지만 EEG 데이터는 다음과 같은 고유한 문제점을 가지고 있다.

1. 데이터 부족 : EEG 데이터는 획득이 어려우며, 라벨링도 전문 지식 필요
2. 다양한 데이터 형식 : 실험마다 전극 개수, 샘플 길이, 태스크 디자인 등이 다름
3. 낮은 신호 대 잡음비(SNR) : EEG 데이터는 잡음이 많아 분석이 어려움

LaBraM(Large Brain Model)은 이러한 문제를 해결하기 위해 대규모 EEG 데이터의 비지도 학습을 수행하는 최초의 모델이다. LaBraM은 EEG 신호를 패치 단위로 분할하여 Transformer 모델을 학습하며, 다양한 EEG 데이터셋에 적용 가능하도록 설계되었다. 본 논문의 기여점은 다음과 같다.

- 대규모 EEG pre-training : 2,500시간 이상의 다양한 EEG 데이터에 대해 대규모 신경 Transformer 모델을 수집하고 사전 학습
- 다양한 EEG 구성과 호환성 : 다양한 채널과 시간 길이를 가진 EEG 신호를 유연하게 처리할 수 있는 모델 제안
- 효과적인 EEG representation learning : EEG 신호의 컴팩트하고 다목적이며 의미 있는 표현을 제공하는 신경 코드북 정의
- 다운스트림 데이터셋에 대한 포괄적인 실험 : BCI의 네 가지 대표적인 다운스트림 작업에서 LaBraMs를 평가하며, 모든 SOTA 방법을 큰 차이로 이김




Figure 1: The overall architecture of LaBraM, i.e., neural Transformer. All input EEG signals will first be segmented into EEG patches through a fixed-length time window, and then a temporal encoder will be applied to each patch to extract temporal features. Afterward, temporal and spatial embeddings are added to the patch features to carry temporal and spatial information. At last, the sequence of embeddings is passed into the Transformer encoder by patch-wise attention to obtain the final output.

Method

Model Architecture

LaBraM의 핵심 개념은 Transformer 기반의 EEG 신호 처리이다.

- EEG 패치 분할 : 원본 EEG 데이터를 일정 시간 단위로 나누어 패치 단위로 처리
- Temporal Encoder : CNN 기반의 시계열 인코더를 사용해 패치별 시간적 특징을 추출
- Temporal & Spatial Embedding : 패치별 시간 및 공간 정보를 추가
- Transformer Encoder: 패치 정보를 Transformer 블록을 통해 인코딩하여 최종 표현 학습

즉, 기존 EEG 모델들이 특정 채널 개수나 데이터 길이에 의존적이었다면, LaBraM은 패치 단위 처리를 통해 다양한 데이터셋에 적응 가능하도록 설계되었다.

Neural Tokenizer Training

LaBraM을 효과적으로 학습하기 위해 EEG 신호를 이산적인(neural tokens) 표현으로 변환하는 신경 토크나이저를 훈련했다.

- EEG 데이터를 Vector-quantized(벡터 양자화) 방식으로 표현
 - Neural Codebook?
 - EEG 데이터를 압축하고 의미 있는 표현으로 변환하는 사전(딕셔너리) 역할을 하는 개념
 - 원래의 연속적인 EEG 신호를 “토큰(token)”이라는 이산적인(discrete) 코드로 변환하는 시스템
 - 동작 방식
 1. EEG 데이터를 패치(작은 조각) 단위로 분할
 - 예를 들어, 1초짜리 EEG 신호를 여러 개의 작은 시간 단위로 나눔
 2. Vector Quantization(벡터 양자화) 수행
 - 분할된 EEG 패치를 기존에 학습된 Neural Codebook과 비교하여 가장 유사한 코드로 변환
 - 마치, “이 신호는 기존의 이 패턴과 가장 비슷해!” 라고 결정하는 것
 3. 각 패치를 특정 코드(토큰)로 변환
 - 예를 들어, EEG 패치 A → 코드 ①, EEG 패치 B → 코드 ②, ... 이런 식으로 변환
 4. Transformer 모델에서 이 코드들을 활용하여 학습 진행
 - 이제 EEG 신호를 연속적인 숫자가 아니라, “의미 있는 코드”들의 조합으로 처리
- Fourier 변환 기반 스펙트럼 예측을 수행하여 신경 임베딩을 생성
- EEG 패치의 위상 및 진폭 정보를 학습하여 신호의 의미를 더 풍부하게 표현

EEG 데이터는 언어처럼 명확한 토큰이 존재하지 않기 때문에, Fourier 변환을 통해 EEG 신호를 보다 의미론적으로 강한 토큰으로 변환하는 과정이 필요했다.

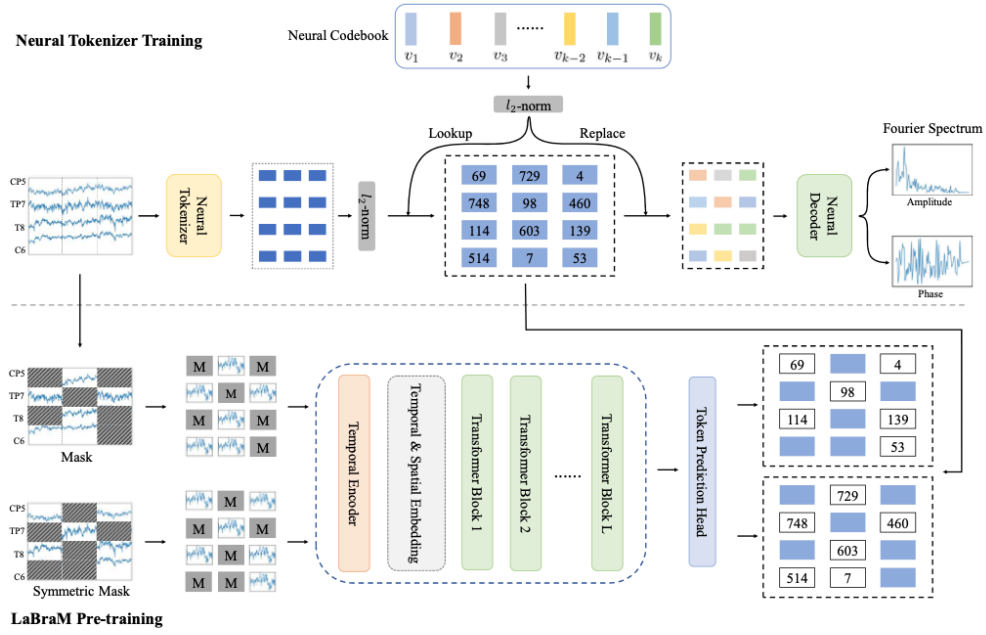


Figure 2: Overview of neural tokenizer training and LaBraM pre-training. **Up:** We train a neural tokenizer to discretize EEG signals into discrete neural tokens by reconstructing the Fourier spectrum. **Down:** During pre-training, part of EEG patches are masked while the objective is to predict masked tokens from visible patches.

Pre-training LaBraM

LaBraM의 사전 학습(pre-training) 은 마스킹된 EEG 패치 복원(masked EEG modeling) 방식으로 진행되었다.

- EEG 패치 중 일부를 마스킹하고, Transformer가 이를 복원하도록 학습
- 대칭 마스킹(Symmetric Masking) 기법을 적용하여 학습 효율을 향상
- 2,500시간 이상의 다양한 EEG 데이터를 활용하여 대규모 학습 수행

마스킹을 통해 모델이 EEG 신호의 본질적인 패턴을 학습할 수 있도록 하였다.

Experiments

Evaluation Datasets

LaBraM은 20개 이상의 EEG 데이터셋, 총 2,500시간 이상의 데이터로 사전 학습되었으며, 주요 다운스트림 태스크에서 평가되었다.

- TUAB (비정상 탐지): 정상/비정상 EEG 분류 (이진 분류)
- TUEV (이벤트 유형 분류): 6가지 EEG 이벤트 분류 (다중 클래스 분류)
- 추가적으로 감정 인식(SEED-V), 보행 예측(MoBI) 등에서도 평가 수행

Experiment Setup

- 모델 크기:
 - LaBraM-Base (5.8M 파라미터)
 - LaBraM-Large (46M 파라미터)
 - LaBraM-Huge (369M 파라미터)
- 하이퍼파라미터:
 - 패치 크기: 1초 (200개 샘플)
 - 마스킹 비율: 50%

- 8개 GPU에서 학습

Table 3: Hyperparameters for vector-quantized neural spectrum prediction training.

Hyperparameters		Values
Temporal Encoder	Input channels	{1,8,8}
	Output channels	{8,8,8}
	Kernel size	{15,3,3}
	Stride	{8,1,1}
	Padding	{7,1,1}
Transformer encoder layers		12
Transformer decoder layers		3
Hidden size		200
MLP size		800
Attention head number		10
Codebook size		8192×64
Batch size		1024
Peak learning rate		5e-5
Minimal learning rate		1e-5
Learning rate scheduler		Cosine
Optimizer		AdamW
Adam β		(0.9,0.99)
Weight decay		1e-4
Total epochs		100
Warmup epochs		10
Data stride		200

Pre-training Visualization

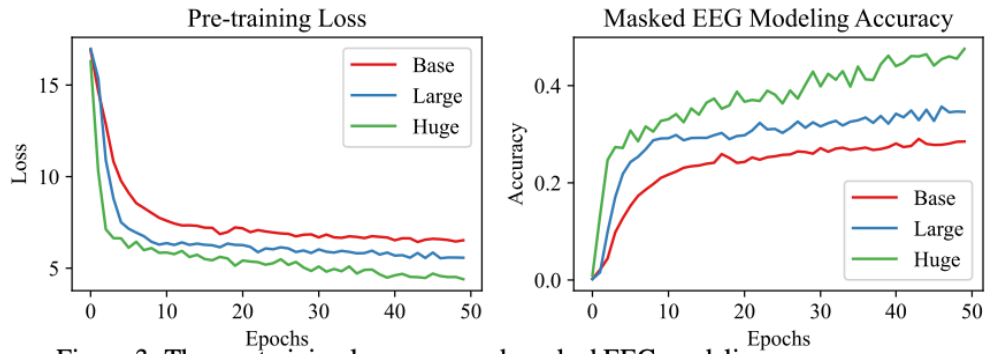


Figure 3: The pre-training loss curve and masked EEG modeling accuracy curve.

- 모델 크기가 커질수록 손실이 더 빠르게 수렴하며, 정확도도 향상됨
- 특히, 대형 모델(LaBraM-Huge)은 더 많은 학습이 진행될수록 성능이 지속적으로 증가

Comparison with State-Of-The-Art

Table 1: The results of different methods on TUAB.

Methods	Model Size	Balanced Accuracy	AUC-PR	AUROC
SPaRCNet (Jing et al., 2023)	0.79M	0.7896±0.0018	0.8414±0.0018	0.8676±0.0012
ContraWR (Yang et al., 2023b)	1.6M	0.7746±0.0041	0.8421±0.0104	0.8456±0.0074
CNN-Transformer (Peh et al., 2022)	3.2M	0.7777±0.0022	0.8433±0.0039	0.8461±0.0013
FFCL (Li et al., 2022)	2.4M	0.7848±0.0038	0.8448±0.0065	0.8569±0.0051
ST-Transformer (Song et al., 2021)	3.5M	0.7966±0.0023	0.8521±0.0026	0.8707±0.0019
BIOT (Yang et al., 2023a)	3.2M	0.7959±0.0057	0.8792±0.0023	0.8815±0.0043
LaBraM-Base	5.8M	0.8140±0.0019	0.8965±0.0016	0.9022±0.0009
LaBraM-Large	46M	0.8226±0.0015	0.9130±0.0005	0.9127±0.0005
LaBraM-Huge	369M	0.8258±0.0011	0.9204±0.0011	0.9162±0.0016

Table 2: The results of different methods on TUEV.

Methods	Model Size	Balanced Accuracy	Cohen's Kappa	Weighted F1
SPaRCNet (Jing et al., 2023)	0.79M	0.4161±0.0262	0.4233±0.0181	0.7024±0.0104
ContraWR (Yang et al., 2023b)	1.6M	0.4384±0.0349	0.3912±0.0237	0.6893±0.0136
CNN-Transformer (Peh et al., 2022)	3.2M	0.4087±0.0161	0.3815±0.0134	0.6854±0.0293
FFCL (Li et al., 2022)	2.4M	0.3979±0.0104	0.3732±0.0188	0.6783±0.0120
ST-Transformer (Song et al., 2021)	3.5M	0.3984±0.0228	0.3765±0.0306	0.6823±0.0190
BIOT (Yang et al., 2023a)	3.2M	0.5281±0.0225	0.5273±0.0249	0.7492±0.0082
LaBraM-Base	5.8M	0.6409±0.0065	0.6637±0.0093	0.8312±0.0052
LaBraM-Large	46M	0.6581±0.0156	0.6622±0.0136	0.8315±0.0040
LaBraM-Huge	369M	0.6616±0.0170	0.6745±0.0195	0.8329±0.0086

- TUAB(비정상 탐지): AUROC 0.9162 (SOTA 대비 +4.5%)
- TUEV(이벤트 분류): Cohen's Kappa 0.6745 (SOTA 대비 +14%)
- SEED-V(감정 인식): Accuracy 41.02% (SOTA 대비 +3%)
- 기존 최신 모델(SOTA) 대비 모든 태스크에서 성능이 향상됨.

Pre-training with/without Downstream Datasets

- 다운스트림 태스크의 데이터를 사전 학습에 포함해도 성능 차이가 크지 않음
- 즉, LaBraM은 특정 태스크가 아닌 범용 EEG 표현을 학습할 수 있음

Scaling Data Size

- 더 많은 데이터 사용 시 성능이 지속적으로 향상됨
- 2,500시간 이상의 데이터가 필요하며, 향후 10,000시간 이상 학습 시 추가 성능 향상 가능성

Conclusions

이 논문에서는 LaBraM이라는 대규모 EEG 모델을 제안했다.

- Transformer 기반 EEG 신호 처리를 도입하여 다양한 태스크에 적용 가능
- 대규모 데이터(2,500시간)와 마스킹 기반 사전 학습 기법을 통해 일반화 성능 강화
- 다양한 다운스트림 태스크에서 최신 연구(SOTA) 대비 높은 성능 달성

향후 연구 방향:

- 더 큰 규모의 EEG 데이터 확보 (~10,000시간)
- 멀티모달 학습 (EEG + 영상, 언어, 음성 등)
- 경량화 모델 연구 (메모리/연산 비용 절감)